Tecnológico Nacional de México
Instituto Tecnológico de Colima

Ingeniería de Datos (ATD-2602) · Unidad 2: Limpieza y Preprocesamiento de Datos

Proyecto Integrador: Pipeline ETL Robusto con Zona de Cuarentena

Reporte comparativo de calidad de datos: antes vs después
Fase 1 (Diagnóstico) y Fase 2 (Faltantes e imputación)

Grupo 2 – Fintech & Transacciones Bancarias (Cajeros ATM + SPEI / App)

Rol: Ingeniera 1 – Calidad, Nulos y Outliers

Nombre del alumno - No. de control

Carol Ivette Rodríguez Lepe - 23460709

Nombre del asesor

Armando Román Gallardo Heredia

Nombre de la carrera

Ingeniería en Sistemas Computacionales

Villa de Álvarez, Col., 25 de octubre de 2026

Reporte comparativo de calidad: antes vs después

Grupo 2 – Fintech & Transacciones Bancarias · Ingeniera 1 (Calidad, Nulos y Outliers): Carol Ivette Rodríguez Lepe · Fases 1 y 2

98.57% → 100%
Completitud global ATM

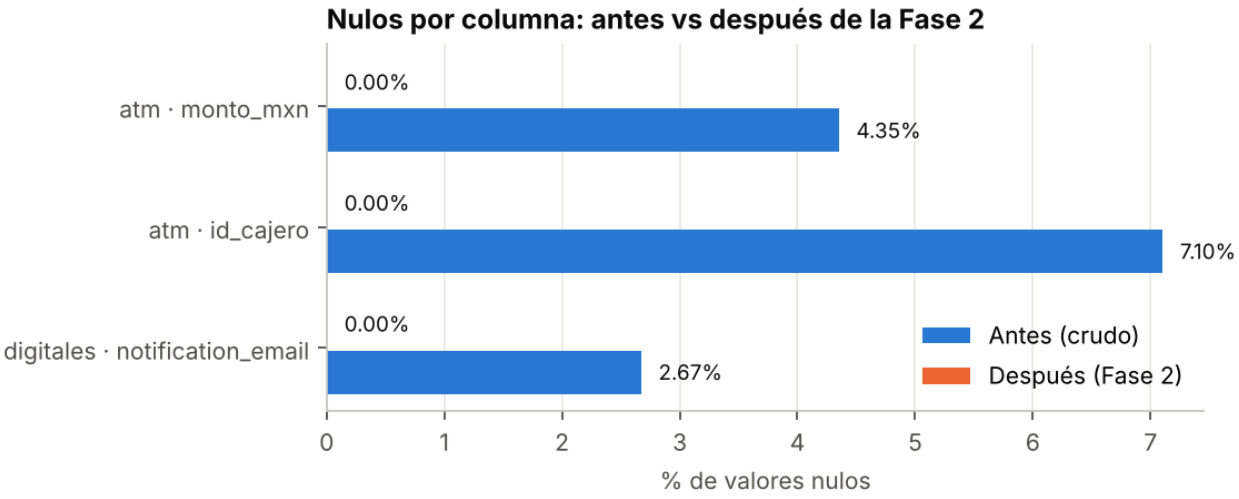
99.73% → 100%
Completitud global SPEI (incluye 8 nulos ocultos)

20 → 0
Duplicados exactos (reintentos de cajero)

85
Valores imputados con bitácora (0 registros válidos eliminados)

1. Resumen por dataset

Dataset	Filas antes	Filas después	Celdas ausentes antes	después	Completitud antes %	después %	Duplicados antes
catalogo_cuentas	50	50	0	0	100.00	100.00	0
transacciones_atm	620	600	71	0	98.57	100.00	20
transferencias_digitales	600	600	16	0	99.73	100.00	0



2. Fase 1 – Diagnóstico del dato crudo

2.1 Nulos disfrazados (carga con `keep_default_na=False, dtype=str`)

Dataset	Columna	Valor encontrado	Conteo
transacciones_atm	monto_mxn	(vacío)	27
transacciones_atm	id_cajero	(vacío)	44
transferencias_digitales	notification_email	(vacío)	8
transferencias_digitales	notification_email		8

Después se carga con `na_values` explícitos. Las 8 cadenas vacías del correo no aparecen en `isna()`: son nulos disfrazados.

2.2 Completitud de menor a mayor: las 3 columnas más críticas

Dataset	Columna	Ausentes	% nulos	% completitud	Crítica
transacciones_atm	id_cajero	44	7.10	92.90	SÍ
transacciones_atm	monto_mxn	27	4.35	95.65	SÍ
transferencias_digitales	notification_email	16	2.67	97.33	SÍ
catalogo_cuentas	estado_cuenta	0	0.00	100.00	
catalogo_cuentas	fecha_apertura	0	0.00	100.00	
catalogo_cuentas	id_cuenta	0	0.00	100.00	

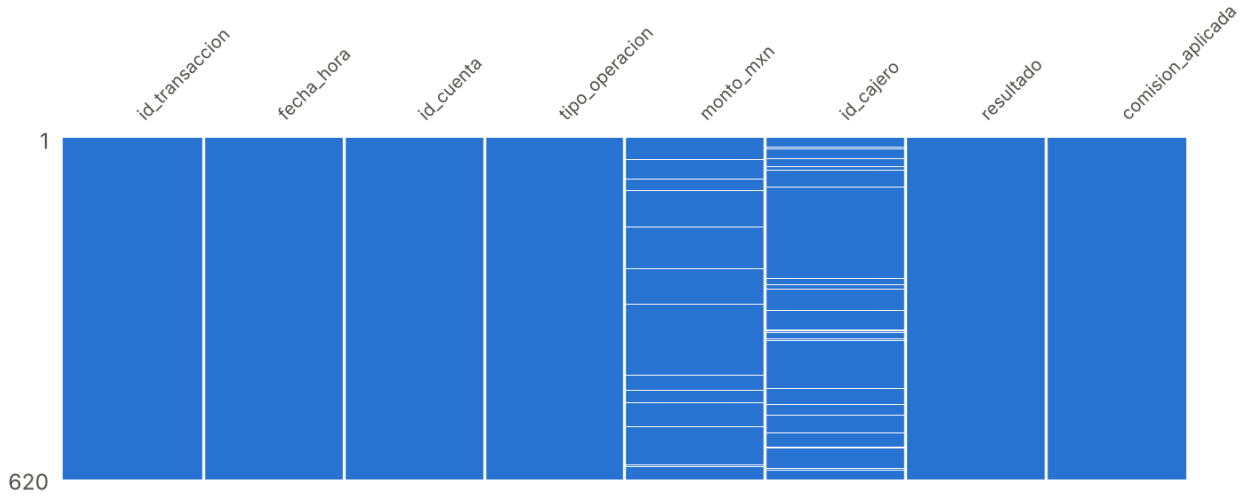
2.3 Perfil por columna (completitud, unicidad y tipos inferidos)

Dataset	Columna	dtype	Tipos Python	Nulos	Ocultos	% nulos	Únicos	% unicidad
catalogo_cuentas	id_cuenta	str	str:50	0	0	0.00	50	100.00
catalogo_cuentas	titular	str	str:50	0	0	0.00	49	98.00
catalogo_cuentas	tipo_cuenta	str	str:50	0	0	0.00	5	10.00
catalogo_cuentas	limite_credito_mxn	float64	float:50	0	0	0.00	5	10.00
catalogo_cuentas	fecha_apertura	str	str:50	0	0	0.00	50	100.00
catalogo_cuentas	estado_cuenta	str	str:50	0	0	0.00	3	6.00
transacciones_atm	id_transaccion	str	str:620	0	0	0.00	600	96.77
transacciones_atm	fecha_hora	str	str:620	0	0	0.00	600	96.77
transacciones_atm	id_cuenta	str	str:620	0	0	0.00	82	13.23
transacciones_atm	tipo_operacion	str	str:620	0	0	0.00	4	0.65
transacciones_atm	monto_mxn	float64	float:593	27	0	4.35	14	2.26
transacciones_atm	id_cajero	str	str:576	44	0	7.10	5	0.81
transacciones_atm	resultado	str	str:620	0	0	0.00	4	0.65
transacciones_atm	comision_aplicada	float64	float:620	0	0	0.00	4	0.65
transferencias_digitales	transfer_id	str	str:600	0	0	0.00	600	100.00
transferencias_digitales	timestamp	object	str:405, int:195	0	0	0.00	598	99.67
transferencias_digitales	account_id	str	str:600	0	0	0.00	79	13.17
transferencias_digitales	amount	float64	float:600	0	0	0.00	600	100.00
transferencias_digitales	currency	str	str:600	0	0	0.00	2	0.33
transferencias_digitales	beneficiary_clabe	int64	int:600	0	0	0.00	555	92.50
transferencias_digitales	notification_email	str	str:592	8	8	2.67	419	69.83
transferencias_digitales	concept	str	str:600	0	0	0.00	6	1.00
transferencias_digitales	status	str	str:600	0	0	0.00	5	0.83
transferencias_digitales	platform	str	str:600	0	0	0.00	4	0.67

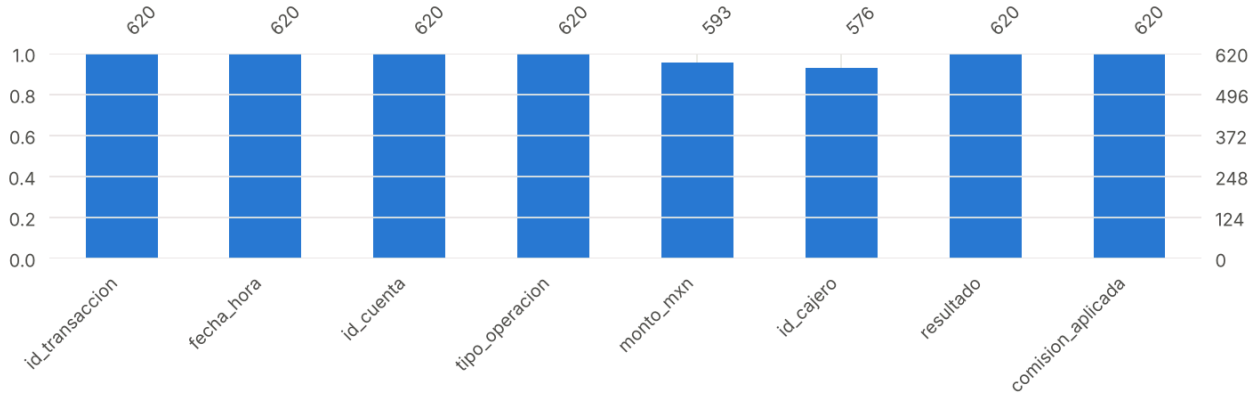
> **Tipo inferido crítico:** con la carga por defecto, `beneficiary_clabe` se infiere como `int64` y se pierde el "0" inicial (554 CLABEs válidas pasan de 18 a 17 dígitos). Regla R1.1: todos los identificadores se leen como texto. `timestamp` es `object` porque mezcla 405 textos ISO-8601 y 195 enteros epoch.

2.4 Patrón visual con missingno

msno.matrix – transacciones_atm (crudo)



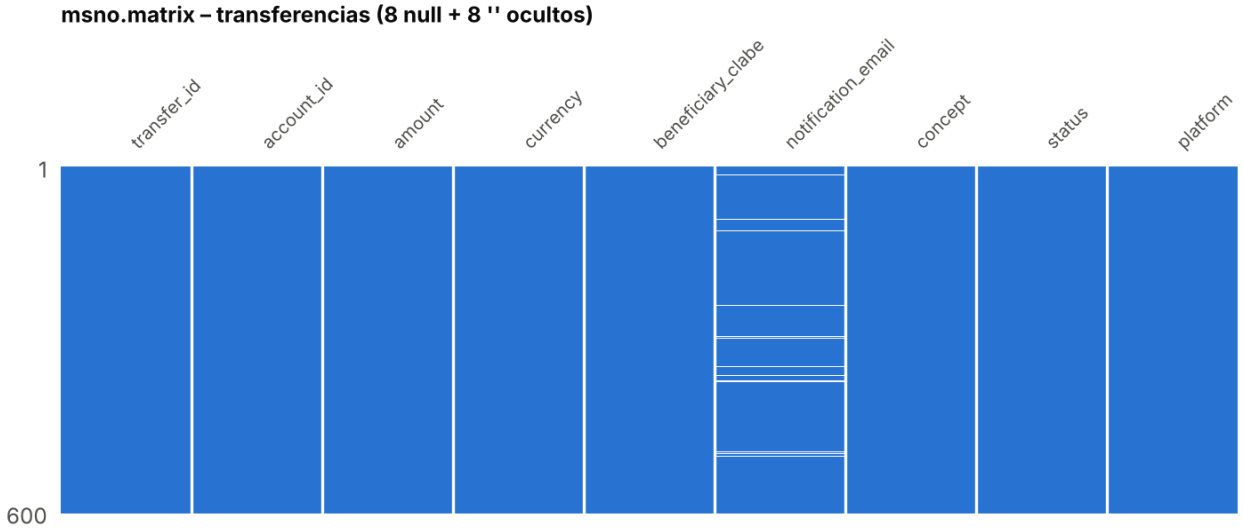
msno.bar – registros con dato por columna (ATM)



msno.heatmap – correlación de nulidad (ATM)



Los nulos están dispersos, sin bloques, y la correlación de nulidad entre `monto_mxn` e `id_cajero` es r = −0.03: no faltan juntos. Es una primera señal de MCAR que luego se confirma con pruebas.


msno.matrix – transferencias (8 null + 8 '' ocultos)
transfer_id
account_id
amount
currency
beneficiary_clabe
notification_email
concept
status
platform
1
600

2.5 Hallazgos de validez transferidos a las Fases 3–7

Dataset	Columna	Hallazgo	Registros	%	Fase
transacciones_atm	(fila completa)	Duplicados exactos = reintentos de cajero (mismo id, fecha, monto y resultado)	20	3.23	Fase 2 (Ing. 1)
transacciones_atm	fecha_hora	Fechas en 3 formatos distintos: '9999/99/99 99:99:99'=220; '99/99/9999 99:99'=200; '9999-99-99 99:99:99'=200	420	67.74	Fase 4 (Ing. 2)
transferencias_digitales	timestamp	timestamp mezcla texto ISO-8601 con zona (-06:00) y enteros epoch Unix	195	32.50	Fase 4 (Ing. 2)
transacciones_atm	resultado	Etiquetas con mayúsculas/minúsculas inconsistentes ('exitosa' vs 'EXITOSA')	85	13.71	Fase 2 (Ing. 1)
transferencias_digitales	status	Etiquetas con mayúsculas/minúsculas inconsistentes ('liquidada' vs 'LIQUIDADA')	121	20.17	Fase 2 (Ing. 1)
transacciones_atm	monto_mxn	monto = 0 en CONSULTA_SALDO (VÁLIDO: una consulta no mueve dinero)	101	16.29	Fase 3 (Ing. 1)
transacciones_atm	monto_mxn	monto <= 0 en operaciones monetarias (imposible)	0	0.00	Fase 3 (Ing. 1)
transacciones_atm	monto_mxn	Montos negativos	0	0.00	Fase 3 (Ing. 1)
transacciones_atm	monto_mxn	Outliers por IQR×1.5 (sobre montos > 0); máximo = 3,500,000 MXN en un ATM	1	0.16	Fase 3 (Ing. 1)
transacciones_atm	monto_mxn	Outliers por Z-score |z| > 3 (sobre montos > 0)	1	0.16	Fase 3 (Ing. 1)
transferencias_digitales	amount	Outliers por Z-score |z| > 3	12	2.00	Fase 3 (Ing. 1)
transferencias_digitales	amount	Montos <= 0	0	0.00	Fase 3 (Ing. 1)
transferencias_digitales	amount	Outliers por IQR×1.5; máximo = 5,240,100	18	3.00	Fase 3 (Ing. 1)
transferencias_digitales	currency	Importes en USD (requieren conversión)	134	22.33	Fase 4 (Ing. 2)
transacciones_atm	comision_aplicada	Comisión = 0.0 (no es NaN; valor de negocio válido = exención)	171	27.58	Fase 2 (Ing. 1)
transacciones_atm	comision_aplicada	Comisión > 0 cobrada en operación con FALLO_CONEXION (anomalía de negocio)	92	14.84	Fase 6 (Ing. 3)
transacciones_atm	id_cuenta	Cuentas huérfanas (no existen en catalogo_cuentas)	32	5.16	Fase 4 (Ing. 2)
transferencias_digitales	account_id	Cuentas huérfanas (no existen en catalogo_cuentas)	29	4.83	Fase 4 (Ing. 2)
transacciones_atm	id_cuenta	Operaciones de cuentas BLOQUEADA/SUSPENDIDA	222	35.81	Fase 6 (Ing. 3)
transferencias_digitales	account_id	Transferencias de cuentas BLOQUEADA/SUSPENDIDA	213	35.50	Fase 6 (Ing. 3)
transferencias_digitales	beneficiary_clabe	CLABE con longitud distinta de 18 dígitos (ej. '12345')	46	7.67	Fase 6 (Ing. 3)
transferencias_digitales	beneficiary_clabe	Carga por defecto la convierte a int64 y PIERDE el '0' inicial (18 → 17 dígitos)	554	92.33	Fase 1 (Ing. 1)
transferencias_digitales	beneficiary_clabe	CLABE de 18 dígitos que NO pasa dígito verificador (informativo, datos sintéticos)	492	82.00	Fase 6 (Ing. 3)
transferencias_digitales	notification_email	Nulos OCULTOS: correo como cadena vacía '' (no aparecen en isna())	8	1.33	Fase 1-2 (Ing. 1)
transferencias_digitales	notification_email	Correo con formato inválido ('correo@@sinformato', 'invalido.com'); sin contar nulos ni ''	30	5.00	Fase 6 (Ing. 3)

> **IQR vs Z-score (actividad 3.1.2):** en SPEI el IQR detecta 18 atípicos y el Z-score solo 12, porque la media y la desviación estándar se inflan con los propios outliers. Para la Fase 3 se recomienda IQR (Tukey).

3. Fase 2 – Clasificación de ausencias (MCAR / MAR)

Como en la sesión 22 se crea el indicador *falta = 1 / no falta = 0* y se revisa si cambia con otra columna observada: % de nulos por categoría (y su brecha en puntos porcentuales) y media de las numéricas con dato vs sin dato. Para saber si una diferencia es real o azar se usa χ^2 de independencia (`scipy.stats.chi2_contingency`; si alguna frecuencia esperada es < 5, su p-valor por permutación) y Mann-Whitney U para numéricas. $\alpha = 0.05$. Para `monto_mxn` se excluye CONSULTA_SALDO, cuyo monto es estructuralmente 0.

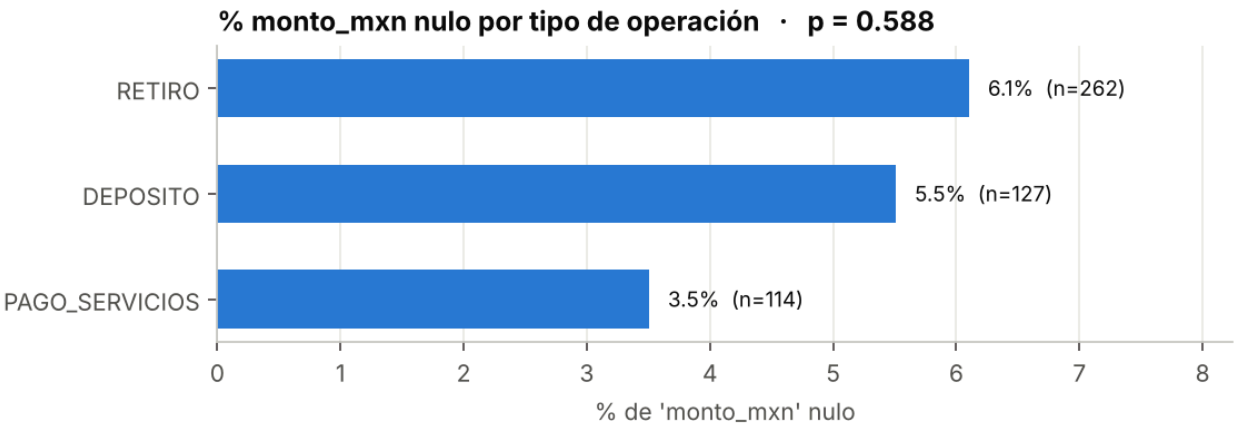
Variable con nulos	n	Vs. variable	Evidencia (sesión 22)	Brecha pp	Prueba	p-valor	p usado	Conclusión
monto_mxn	27	tipo_operacion	DEPOSITO=5.5%; PAGO_SERVICIOS=3.5%; RETIRO=6.1%	2.6	Chi² de independencia	0.5879	chi² clásica	MCAR
monto_mxn	27	resultado	EXITOSA=5.3%; FALLO_CONEXION=4.0%; FALLO_FONDOS=7.1%	3.1	Chi² de independencia	0.6079	permutación (esperadas < 5)	MCAR
monto_mxn	27	id_cajero	ATM-COL-01=9.7%; ATM-COL-02=4.7%; ATM-MZL-01=5.5%; ATM-TECO-01=3.1%; ATM-VDA-01=3.8%	6.6	Chi² de independencia	0.3505	permutación (esperadas < 5)	MCAR
monto_mxn	27	comision_aplicada	media comision_aplicada: con dato=18.15 / sin dato=18.28; mediana: con dato=15.00 / sin dato=25.00		Mann-Whitney U	0.9260	Mann-Whitney	MCAR
id_cajero	42	tipo_operacion	CONSULTA_SALDO=10.3%; DEPOSITO=7.9%; PAGO_SERVICIOS=7.0%; RETIRO=5.3%	5.0	Chi² de independencia	0.4097	chi² clásica	MCAR
id_cajero	42	resultado	EXITOSA=7.4%; FALLO_CONEXION=8.5%; FALLO_FONDOS=3.8%	4.7	Chi² de independencia	0.3488	chi² clásica	MCAR
id_cajero	42	monto_mxn	media monto_mxn: con dato=10052.26 / sin dato=2717.07; mediana: con dato=1500.00 / sin dato=1000.00		Mann-Whitney U	0.1451	Mann-Whitney	MCAR
id_cajero	42	comision_aplicada	media comision_aplicada: con dato=17.91 / sin dato=20.66; mediana: con dato=15.00 / sin dato=25.00		Mann-Whitney U	0.2017	Mann-Whitney	MCAR
notification_email	16	status	DEVUELTA=2.3%; LIQUIDADA=4.2%; PENDIENTE=2.6%; RECHAZADA=0.0%	4.2	Chi² de independencia	0.1196	permutación (esperadas < 5)	MCAR
notification_email	16	currency	MXN=2.6%; USD=3.0%	0.4	Chi² de independencia	1.0000	permutación (esperadas < 5)	MCAR

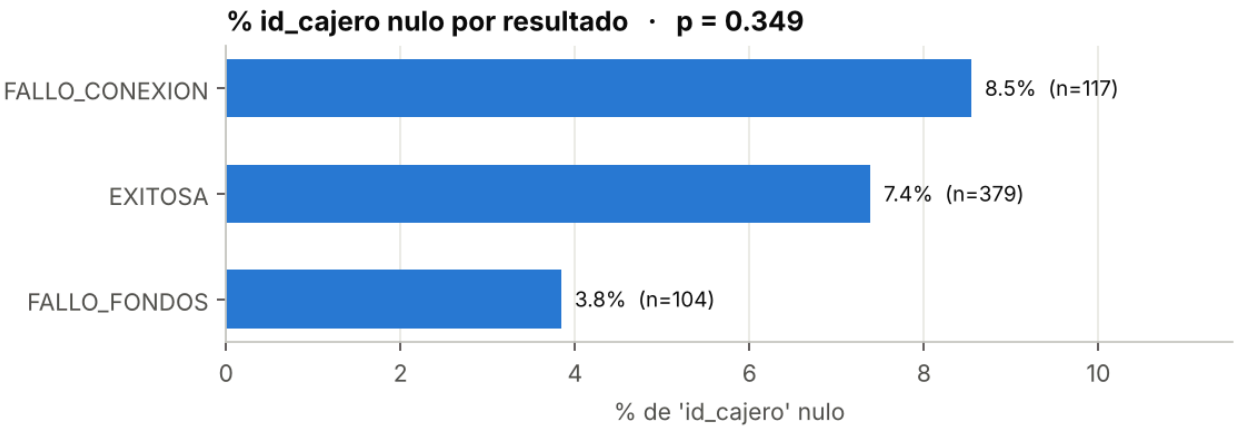
Variable con nulos	n	Vs. variable	Evidencia (sesión 22)	Brecha pp	Prueba	p-valor	p usado	Conclusión
notification_email	16	concept	Comida=4.3%; Nómina=3.2%; Pago Renta=2.1%; Préstamo=3.7%; Servicios=2.6%; Transferencia=0.0%	4.3	Chi² de independencia	0.5395	permutación (esperadas < 5)	MCAR
notification_email	16	platform	API EMPRESARIAL=1.8%; APP ANDROID=3.4%; APP IOS=3.6%; WEB BANKING=2.0%	1.8	Chi² de independencia	0.6749	permutación (esperadas < 5)	MCAR
notification_email	16	amount	media amount: con dato=100395.66 / sin dato=20376.17; mediana: con dato=18346.96 / sin dato=24080.41		Mann-Whitney U	0.3484	Mann-Whitney	MCAR

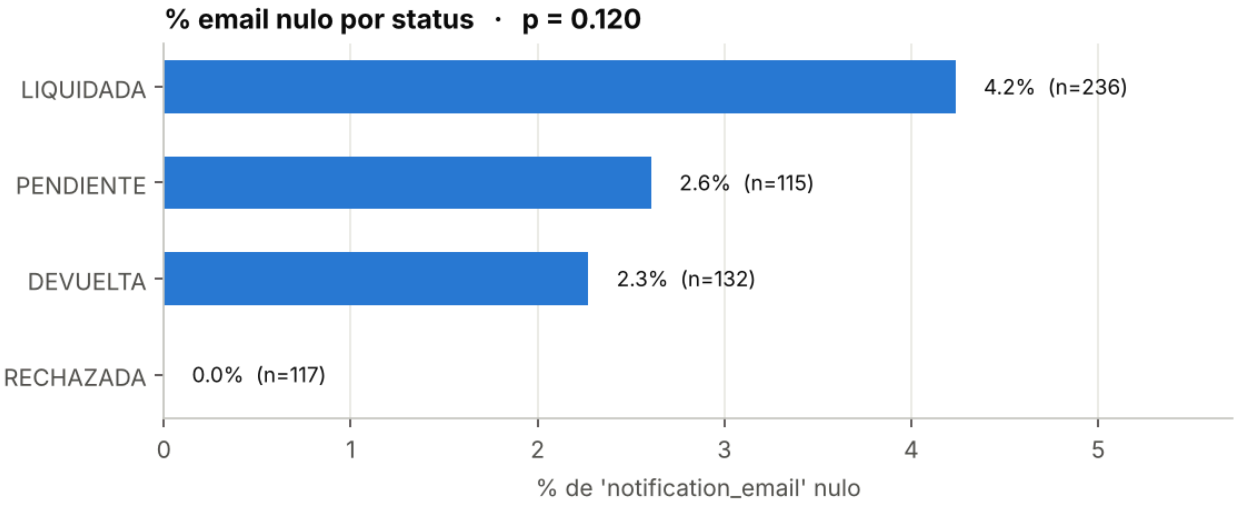
Sensibilidad: si se ignoran los 8 nulos ocultos (`''`) del correo, la prueba contra `status` da p = 0.034 y se concluiría erróneamente MAR. Con los 16 ausentes reales, p = 0.120 → MCAR. Por eso la normalización de nulos ocultos va antes de la clasificación.

Discusión MNAR (se argumenta con el negocio)

Columna	¿Podría faltar por su propio valor?	Conclusión
monto_mxn	Sería MNAR si los montos grandes se perdieran más. La falta no depende de tipo, resultado, cajero ni comisión, que están ligadas al monto, y en un cajero el monto lo registra el sistema.	MCAR
id_cajero	El ID lo escribe la terminal; su ausencia es una falla de telemetría que no depende de qué cajero era.	MCAR
notification_email	El cliente no registró correo; no se relaciona con el monto ni con el estado.	MCAR

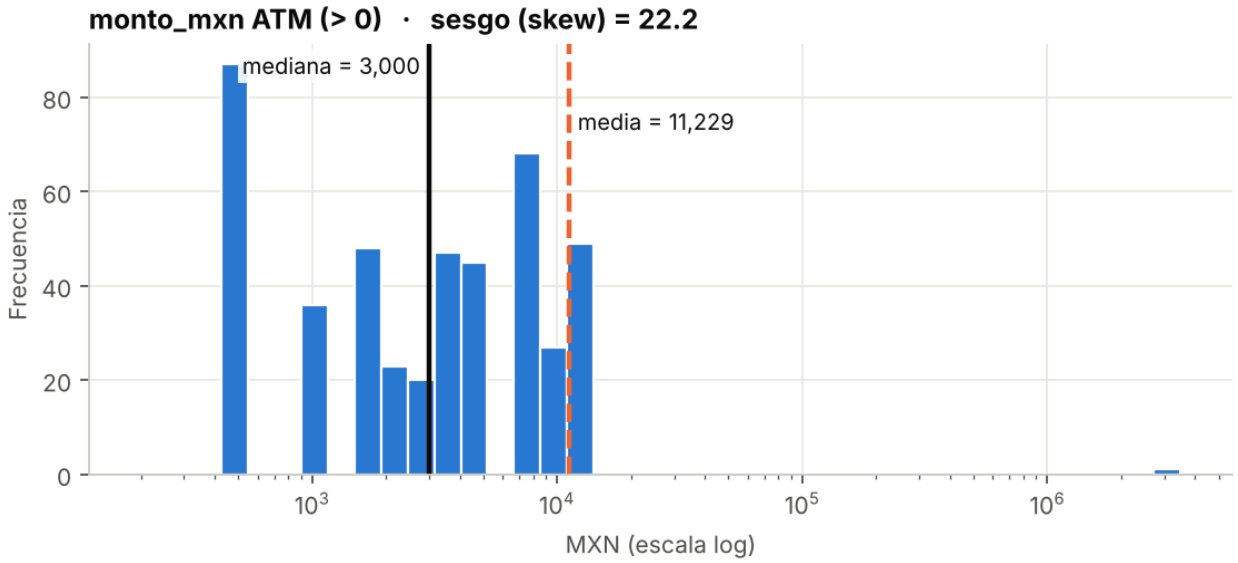


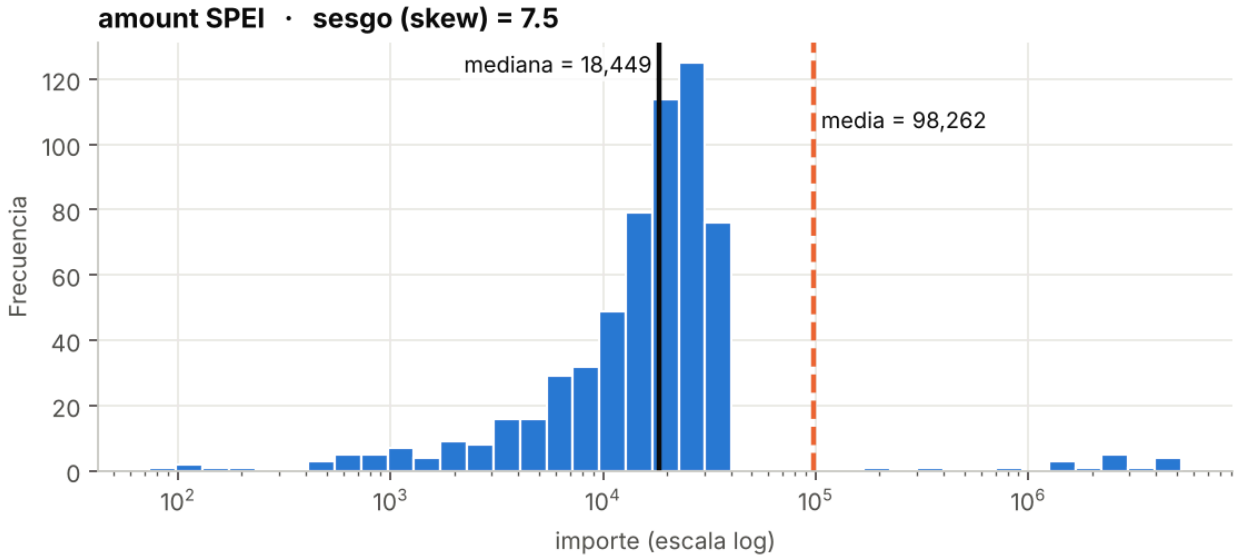

% id_cajero nulo por resultado · p = 0.349
FALLO_CONEXION
EXITOSA
FALLO_FONDOS
8.5% (n=117)
7.4% (n=379)
3.8% (n=104)
0
2
4
6
8
10
% de 'id_cajero' nulo


% email nulo por status · p = 0.120
LIQUIDADA
PENDIENTE
DEVUELTA
RECHAZADA
4.2% (n=236)
2.6% (n=115)
2.3% (n=132)
0.0% (n=117)
0
1
2
3
4
5
% de 'notification_email' nulo

4. Fase 2 – Imputación

4.1 Por qué la mediana y no la media





Los importes están fuertemente sesgados a la derecha (sesgo 22.2 en ATM y 7.5 en SPEI). La media se dispara por valores extremos (3 500 000 MXN en un cajero) y queda 3.7 a 5.3 veces por encima de la mediana, así que no representa una operación típica. La mediana tiene un punto de ruptura del 50 % frente al 0 % de la media. Se imputa por grupo (`tipo_operacion` / `currency`) para respetar que cada tipo tiene su propio nivel típico.

4.2 ¿Mediana global (SimpleImputer, sesión 28) o mediana por grupo?

tipo_operacion	Nulos a imputar	Mediana global (SimpleImputer)	Mediana por grupo (pipeline)	Diferencia MXN	Media del grupo
DEPOSITO	7	3,000.00	4,000.00	1,000.00	4,741.67
PAGO_SERVICIOS	4	3,000.00	4,000.00	1,000.00	5,345.45
RETIRO	16	3,000.00	2,000.00	-1,000.00	17,488.62

`SimpleImputer(strategy="median")` pondría 3 000 MXN a todos los faltantes. Un retiro típico es de 2 000 y un depósito de 4 000, y la media de RETIRO es 17 489 por el outlier. Por eso se imputa con la mediana dentro de cada `tipo_operacion`. La imputación categórica es idéntica a `SimpleImputer(strategy="constant")` y las banderas `<col>_imputado` cumplen la función de `add_indicator=True`.

Dataset	Variable	Grupo	Mediana usada
transacciones_atm	monto_mxn	DEPOSITO	4,000.00
transacciones_atm	monto_mxn	PAGO_SERVICIOS	4,000.00
transacciones_atm	monto_mxn	RETIRO	2,000.00
transferencias_digitales	amount	MXN	18,426.85
transferencias_digitales	amount	USD	19,356.64

4.3 Reglas aplicadas y bitácora

Variable	Tipo de ausencia	Regla
monto_mxn (CONSULTA_SALDO)	Deducible	Se recalcula = 0 a partir de tipo_operacion (en este lote aplicó a 0 registros; regla activa y probada)
monto_mxn	MCAR	Mediana por tipo_operacion (solo montos > 0)
id_cajero	MCAR	Etiqueta controlada CAJERO_DESCONOCIDO
notification_email	MCAR	Etiqueta controlada ANONIMO
comision_aplicada	Sin nulos	0.0 = exención válida (se conserva); NaN futuro → mediana por tipo
Llaves / CLABE / fechas / moneda	—	Nunca se imputan → cuarentena
Valor corrupto (ej. 'abc')	—	No se imputa; se anota en obs_calidad → cuarentena

Dataset	Columna	Método	Registros imputados
transacciones_atm	id_cajero	ETIQUETA CONTROLADA 'CAJERO_DESCONOCIDO'	42
transacciones_atm	monto_mxn	MEDIANA por tipo_operacion	27
transferencias_digitales	notification_email	ETIQUETA CONTROLADA 'ANONIMO'	16

4.4 La imputación no distorsiona la distribución

Variable	Etapa	No nulos	Nulos	Media	Mediana	Desv. std	Sesgo
monto_mxn (ATM)	antes (crudo)	593	27	9,316.53	1,500.00	143,637.62	24.33
monto_mxn (ATM)	después (Fase 2)	600	0	9,225.33	1,500.00	142,797.13	24.47
amount (SPEI)	antes (crudo)	600	0	98,261.81	18,448.76	533,615.81	7.47
amount (SPEI)	después (Fase 2)	600	0	98,261.81	18,448.76	533,615.81	7.47

La mediana de `monto_mxn` se mantiene en 1 500 MXN y la media cambia −1.0 %. Los outliers siguen presentes a propósito: los trata la Fase 3 con IQR y capping.

5. Conclusiones y entrega a la siguiente fase

- Completitud de 100 % en las tres fuentes; los 20 reintentos de cajero se eliminaron y no se perdió ningún registro válido.
- Las tres ausencias son MCAR (ninguna prueba con p < 0.05, nulidad dispersa y no correlacionada, MNAR descartado por negocio). Se imputó con la mediana por grupo (numéricas) y con etiquetas controladas (categóricas), y cada valor imputado quedó en la bitácora.
- Salidas: `data/interim/*_fase2.*`, con las columnas `<col>_imputado` y `obs_calidad`.
- Para la Fase 3: excluir CONSULTA_SALDO (101 registros con monto 0 legítimo) de la regla “monto ≤ 0”.
- Para el Ing. 3: leer la CLABE como texto y aceptar `ANONIMO` en el validador de correo.